



UNIVERSITÀ DEGLI STUDI
DEL SANNIO Benevento

CORSO DI LAUREA MAGISTRALE DI SCIENZE
STATISTICHE E ATTUARIALI

MODELLI DI VALUTAZIONE E PROCEDURE
DECISIONALI

Analisi del Dataset Credit Score Classification

Studente:

Francesco Cuozzo

Matricola:

709000613

14 maggio 2025

Indice

1	Introduzione	2
2	Analisi Esplorativa dei Dati	3
2.1	Statistiche Descrittive	3
2.2	Preprocessing dei Dati	4
3	Modellazione	6
3.1	Rete Neurale	6
3.1.1	Architettura della Rete Neurale	6
3.1.2	Tecniche di regolarizzazione	8
3.1.3	Validazione Risultati	8
3.2	Random Forest	9
4	Conclusioni	11

Capitolo 1

Introduzione

Questo report presenta un'analisi approfondita del dataset *Credit Score Classification*, ([https://https://www.kaggle.com/datasets/parisrohan/credit-score-classification](https://www.kaggle.com/datasets/parisrohan/credit-score-classification)) con l'obiettivo di sviluppare un modello di Deep Learning in grado di prevedere il Credit Score di un individuo sulla base delle sue caratteristiche finanziarie. Il dataset contiene informazioni su circa 100.000 individui, tra cui età, occupazione, reddito annuo, debito residuo e altre variabili rilevanti.

Capitolo 2

Analisi Esplorativa dei Dati

2.1 Statistiche Descrittive

Questo dataset descrive il profilo finanziario di un campione di circa 100.000 individui sulla base delle seguenti caratteristiche.

Variabili utilizzate:

- **Age:** età
- **Occupation:** professione
- **Annual_Income:** Reddito annuo
- **Monthly_Inhand_Salary:** Stipendio mensile
- **Num_Bank_Accounts:** Numero di conti bancari per individuo
- **Num_Credit_Card:** Numero delle carte di credito per individuo
- **Interest_Rate:** Tasso di interesse applicato sulle carte di credito
- **Num_of_Loan:** Numero di prestiti
- **Type_of_Loan:** Tipo di prestito
- **Delay_from_due_date:** Numero medio di giorni di ritardo dalla data di pagamento
- **Num_of_Delayed_Payment:** Numero medio di pagamenti fatti in ritardo da una persona

- **Changed_Credit_Limit:** Variazione percentuale del limite della carta di credito
- **Num_Credit_Inquiries:** Numero di richieste di carte di credito
- **Credit_Mix:** Crediti misti per differenti tipologie di prestiti
- **Outstanding_Debt:** Debito restante da pagare espresso in dollari
- **Credit_Utilization_Ratio:** Utilizzo medio delle carte di credito
- **Credit_History_Age:** Storia creditizia dell'individuo
- **Payment_of_Min_Amount:** Indica se la persona ha pagato solo l'importo minimo
- **Total_EMI_per_month:** Pagamenti mensili EMI
- **Amount_invested_monthly:** Importo mensile investito dal cliente (in USD)
- **Payment_Behaviour:** Comportamento di pagamento del cliente (in USD)
- **Monthly_Balance:** Importo del saldo mensile del cliente (in USD)
- **Credit_Score:** Fascia del punteggio di credito (*Poor, Standard, Good*)

2.2 Preprocessing dei Dati

- **Encoding delle variabili categoriche:** Le variabili categoriche (*occupation, credit_mix, type_of_loan, payment_behaviour, payment_of_min_amount*) sono state codificate utilizzando `LabelEncoder`.
- **Scaling delle variabili numeriche:** Le variabili numeriche sono state scalate utilizzando `MinMaxScaler` per portarle in un range compreso tra 0 e 1.
- **Divisione del dataset:** Il dataset è stato diviso in training set (70%), validation set (15%) e test set (15%) per addestrare, validare e testare il modello.

Figura 2.1: All'aumentare del Credit Score, aumenta anche la storia creditizia (mediana più alta).

Le persone con credit score alto tendono ad avere una storia creditizia più lunga. Gli outlier con credit score *Good* (2) mostrano che ci sono anche persone con storia creditizia molto breve ma con buon punteggio.

Figura 2.2: Il credit score *Standard* è quello più diffuso in tutti i lavori.

Nessuna professione sembra garantire un'elevata concentrazione di punteggi di credito *Good*, cioè alti, ad eccezione delle professioni “Developer” e “Engineer”. Alcune professioni artistiche o accademiche tendono a mostrare più punteggi bassi. Anche tra professioni molto ben retribuite come “Lawyer” e “Doctor”, il credit score *Good* è visibilmente inferiore rispetto agli altri gruppi.

Figura 2.3: Distribuzione di Outstanding Debt per Credit Score (Violin Plot).

Questo tipo di grafico combina un boxplot con una stima della densità. All'aumentare del credit score, il debito residuo tende a diminuire. Le persone con credit score *Good* sono associate a un debito residuo più basso e una distribuzione più stabile. Chi ha credit score *Poor* mostra una grande variabilità nei debiti e livelli medi più alti.

Figura 2.4: L'andamento conferma una correlazione inversa tra Debito residuo e Credit Score.

Capitolo 3

Modellazione

3.1 Rete Neurale

3.1.1 Architettura della Rete Neurale

Il modello sviluppato è una rete neurale feed-forward sequenziale progettata per la classificazione multi-classe. L'architettura complessiva è la seguente:

- **Layer 1:** Dense fully-connected con 128 unità e funzione di attivazione ReLU. La funzione di attivazione ReLU (*Rectified Linear Unit*) è definita come:

$$\text{ReLU}(x) = \max(0, x)$$

- **Layer 2:** Dropout con tasso di abbandono $p = 0.3$, applicato per ridurre l'overfitting. Durante l'allenamento, il 30% dei neuroni viene disattivato casualmente.
- **Layer 3:** Dense fully-connected con 64 unità e attivazione ReLU (come sopra).
- **Layer 4:** Dropout con tasso di abbandono $p = 0.3$ (identico al precedente).
- **Layer di output:** Dense con 3 unità (una per ciascuna classe target), con funzione di attivazione softmax. La funzione softmax è definita come:

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}, \quad \text{per } i = 1, \dots, K$$

dove $K = 3$ è il numero delle classi.

Iperparametri di Addestramento:

- **Ottimizzatore:** Adam (*Adaptive Moment Estimation*), che combina i vantaggi di AdaGrad e RMSProp. L'aggiornamento dei pesi segue:

$$\theta_{t+1} = \theta_t - \eta \cdot \frac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}$$

dove $\hat{m}_t$ e $\hat{v}_t$ sono le stime corrette dei momenti primo e secondo, rispettivamente, η è il learning rate e ϵ è un piccolo termine di stabilizzazione numerica.

- **Funzione di perdita:** `sparse_categorical_crossentropy`, adatta per classificazione multi-classe con etichette intere. È definita come:

$$\mathcal{L}(y, \hat{y}) = -\log(\hat{y}_y)$$

dove y è l'etichetta intera della classe corretta, e $\hat{y}_y$ è la probabilità predetta per quella classe.

- **Metrica di valutazione:** Accuratezza (*Accuracy*), definita come:

$$\text{Accuracy} = \frac{\text{numero di predizioni corrette}}{\text{numero totale di campioni}}$$

Layer	Output Shape	Numero Parametri
dense_3 (Dense)	(None, 128)	2 944
dropout_2 (Dropout)	(None, 128)	0
dense_4 (Dense)	(None, 64)	8 256
dropout_3 (Dropout)	(None, 64)	0
dense_5 (Dense)	(None, 3)	195

Tabella 3.1: Struttura riassuntiva dell'architettura della rete neurale.

Figura 3.1: Schema visivo dell'architettura della rete neurale.

Figura 3.2: Architettura della rete neurale con classi di output etichettate (0, 1, 2).

3.1.2 Tecniche di regolarizzazione

Durante l'addestramento della rete neurale, è stata utilizzata la tecnica di **Early Stopping** come strategia di regolarizzazione per prevenire l'overfitting. Questo algoritmo monitora l'andamento della funzione di perdita sul validation set e interrompe l'allenamento quando questa smette di migliorare per un numero definito di epoche consecutive (in questo caso 5).

Nella nostra analisi, l'allenamento è stato interrotto automaticamente alla 28^a epoca, poiché la funzione di loss aveva iniziato a peggiorare, indicando una possibile perdita di capacità di generalizzazione del modello. L'utilizzo di questa tecnica ha permesso di:

- evitare l'overfitting sui dati di training;
- ridurre i tempi di addestramento;
- conservare un modello con prestazioni ottimali sul validation set.

L'andamento della funzione di perdita, che mostra la risalita della validation loss, è riportato in Figura 3.3.

Un'altra tecnica usata per evitare l'overfitting è quella del **Dropout**, che consiste nel tagliare, in maniera casuale, la percentuale di collegamento dei nodi. In questo modo si impedisce al modello di dipendere troppo da un nodo o una combinazione di essi, in modo tale da avere dei risultati più robusti.

La differenza fondamentale tra le due tecniche di regolarizzazione è che mentre il dropout agisce direttamente sull'allenamento, andando a tagliare i collegamenti tra gli strati, l'early stopping agisce sulla fase di addestramento finale, fermandolo anticipatamente prima che le performance peggiorino.

Figura 3.3: Andamento della loss durante l'addestramento.

3.1.3 Validazione Risultati

Per spiegare i risultati ottenuti abbiamo utilizzato come prima cosa una **matrice di confusione**. Questa matrice permette di classificare le previsioni del nostro modello, mettendole in relazione alle osservazioni reali. Abbiamo ottenuto una *Accuracy* del 70%. Tuttavia non tutte le categorie si sono comportate allo stesso modo. Notiamo che il modello è più preciso su *Standard* rispetto a *Poor* e *Good*; si nota infatti che 1210 su 4123 osservazioni di *Poor* vengono mal classificati come *Standard*.

Un altro metodo utile per controllare la corretta classificazione è la **curva ROC**. Questa curva viene tracciata secondo i livelli di sensitività (sull'asse delle ascisse) e di specificità (sull'asse delle ordinate). Si va poi a controllare l'area sottesa a questa curva (definito come *AUC – area under the curve*). La classificazione sarebbe ottimale se riuscisse a massimizzare entrambe le metriche. Più alto è il valore di AUC, migliore è la classificazione del modello. Anche in questo caso notiamo come la classificazione per la variabile *Standard* si comporta in maniera peggiore rispetto alle altre due.

L'ultimo metodo utilizzato è quello del **calibration plot**. Un grafico di calibrazione è uno strumento molto utile per andare a controllare la corretta classificazione del modello. Esso si compone in due step principali:

- **Binning delle probabilità:** Le probabilità previste dal modello vengono suddivise in intervalli o “bin”. Nel nostro caso sono stati utilizzati intervalli di 0.20.
- **Calcolo della media delle probabilità previste e della frequenza reale:** Per ciascun bin, si calcola la media delle probabilità previste dal modello e la frequenza reale delle osservazioni appartenenti a quella classe. Ad esempio, se si hanno 100 osservazioni nel bin $[0.2; 0.4]$, si calcola la media delle probabilità previste per quel bin e la percentuale effettiva di casi positivi nel bin.

A questo punto si costruisce il grafico, con l'asse delle Y avente le frequenze reali e l'asse delle X le probabilità. Il modello ideale dovrebbe avere tutti i punti sulla bisettrice; se i punti sono al di sotto della bisettrice, il nostro modello andrà a sovrastimare la probabilità. Viceversa, se si trovano al di sopra andrà a sotto-stimarla.

Da quest'ultimo metodo si può notare come la variabile *Good*, nonostante sia quella meglio classificata, sia sovrastimata per classi alte.

(a) Matrice di confusione (b) Curve ROC (c) Calibration plot

Figura 3.4: Grafici di validazione dei risultati per la rete neurale.

3.2 Random Forest

Per provare a classificare meglio questo tipo di dati, oltre a una rete neurale, è stato costruito anche un modello di **Random Forest**. Questo modello, mettendo insieme un gran numero di alberi decisionali, consiste nel selezionare in modo casuale,

ad ogni nodo dell'albero, un piccolo gruppo di variabili esplicative che verranno ispezionate per individuare il punto di suddivisione ottimale. In questo modo non si esplorerebbero tutti i punti di suddivisione, ma solo quelli relativi alle variabili scelte casualmente. L'albero viene fatto crescere fino alla sua massima dimensione e non viene perciò potato. Sarà infatti la combinazione di diversi alberi che permetterà di evitare i problemi di overfitting.

Per addestrare al meglio una random forest si è proceduto ad un tuning automatico degli iperparametri, che ci ha portato ad avere i seguenti risultati:

- `max_depth = 10`: la lunghezza massima che devono avere gli alberi.
- `min_samples_leaf = 3`: numero minimo di campioni che devono essere presenti in un nodo foglia (il nodo finale) di ogni albero.
- `min_samples_split = 2`: numero minimo di campioni che devono essere presenti in un nodo interno prima che questo possa essere diviso.
- `n_estimators = 140`: il numero di alberi usati per l'addestramento.

Grazie ad essi si è riuscito a trovare un buon equilibrio tra under e over fitting.

È stato usato un modello come questo, diverso da una rete neurale, per la sua facilità di addestramento e per la sua interpretabilità. Inoltre questo tipo di modello va a fare automaticamente una selezione delle variabili più importanti.

La random forest si è dimostrata leggermente più accurata della rete neurale, avendo una percentuale di ben classificati di circa il 73%. Anche in questo caso però la modalità *poor* non viene classificata al meglio: difatti solo circa il 60% delle osservazioni viene correttamente classificato come *poor*.

Andando a vedere invece i risultati dati dal calibration plot e dalle curve ROC, si nota come è la modalità *standard* che ha più problemi, soprattutto riguardanti frequenze alte, dove viene fortemente sovrastimata.

(a) Matrice di confusione (b) Curve ROC (c) Calibration plot

Figura 3.5: Grafici di validazione dei risultati per la random forest.

Capitolo 4

Conclusioni

L'analisi svolta sul dataset *Credit Score Classification* ha permesso di approfondire la relazione tra caratteristiche finanziarie individuali e l'attribuzione del punteggio di credito. La fase di analisi esplorativa ha evidenziato pattern significativi, come l'associazione positiva tra la lunghezza della storia creditizia e un punteggio di credito elevato, e la correlazione inversa tra debito residuo e credit score. È emerso anche che il tipo di occupazione non è sempre un predittore affidabile di buon punteggio, in quanto professioni ad alto reddito (come medici o avvocati) non mostrano necessariamente una prevalenza di credit score *Good*.

La rete feed-forward ha avuto un'accuracy soddisfacente, di circa il 70%, con dei problemi significativi riguardanti la corretta classificazione della modalità *Standard*. L'uso di tecniche di regolarizzazione quali early-stopping e dropout ha permesso un allenamento più snello, senza perdere troppo in accuratezza.

Poteva essere usata anche una rete di tipo LSTM. È stata preferita una semplice rete feed-forward, poiché i dati non presentavano una componente temporale.

L'uso della random forest ha permesso di controllare la validità dei risultati, con un allenamento molto meno dispendioso in termini di tempo.

In definitiva si può considerare come soddisfacente la rete neurale addestrata. Ulteriori miglioramenti potrebbero essere fatti introducendo un'architettura diversa e più complessa o anche scegliendo un dataset di dimensioni maggiori, visto che l'addestramento di una rete neurale funziona meglio con dataset superiori alle 300.000 osservazioni.